




Super-Convergence

Краткий обзор статьи <https://arxiv.org/pdf/1708.07120>




Стандартное обучение с шедулером

Обычно для обучения используем следующую эвристику - небольшой lr , постепенно его уменьшаем для лучшей сходимости. Самые популярные шедулеры - cosine и ReduceLROnPlateau.



Шедулер, предлагаемый в статье

Предлагается сначала увеличивать lr до больших значений, потом уменьшать, в отличие от циклических шедулеров хотим пройти только один раз. Утверждается, что таким образом сходимости можно достигнуть гораздо быстрее. На ResNet-56 авторы обнаружили, что обучение может оставаться успешным при LR порядка единиц — значительно выше стандартных значений около 0.1.



Почему это вообще работает?


Авторы приводят несколько мотиваций: большой λ не дает застрять в локальном минимуме и работает как регуляризация (модель быстрее покидает области с высокой кривизной лосса). Авторы называют это неявной регуляризацией.

Большой λ , как можно показать, ограничивает кривизну локального минимума, в котором оптимизация может устойчиво сойтись. Также авторы говорят, что нужно уменьшить другие используемые виды регуляризации, например weight decay.


Estimating optimal learning rates

Авторы выводят через разложение второго порядка формулу для оптимального данного lr на шаге, связывая ее с кривизной, затем агрегируют многомерную оценку, получая оптимальный lr для конкретного шага. Используют метод конечных разностей. Ниже приведены графики оцененного lr для фиксированного lr и предлагаемого 1cyclelr.

$$\epsilon^* = \epsilon \frac{\theta_{i+1} - \theta_i}{2\theta_{i+1} - \theta_i - \theta_{i+2}}$$



(a) Estimated learning rates computed from the weights at every iteration for 300 iterations.




(b) Estimated learning rates computed from the weights at every 10 iterations for 10,000 iterations.

Как выбрать максимальный LR?

Делаем много пробных запусков, увеличивая максимальный lr. Смотрим, при каких значениях модель все еще хорошо учится

Если при увеличении лр качество сначала улучшается, а затем резко ухудшается, мы приблизились к области нестабильного обучения.




Главный эксперимент с ResNet-56 на CIFAR-10


Авторы сравнили стандартное обучение SGD с momentum и обучение с использованием 1cycle.

Обычное обучение: 91.2% за 80 000 итераций.

Super-Convergence: 92.4% за 10 000 итераций.



(a) Comparison of test accuracies for Cifar-10/Resnet-56 with limited training samples.



(b) Comparison of test accuracies for Resnet-20 and Resnet-110.

Figure 4: Comparisons of super-convergence to typical training outcome with piecewise constant learning rate schedule.

Что если обучающих данных мало?

Super-Convergence особенно полезен при малом количестве данных.

Чем меньше данных, тем заметнее выигрыш в accuracy.

Авторы интерпретируют это как дополнительное подтверждение регуляризующего эффекта больших lr.


# training samples	Policy (Range)	BN MAF	Total Iterations	Accuracy (%)
40,000	PC-LR=0.35	0.999	80,000	89.1
40,000	CLR (0.1-3)	0.95	10,000	91.1
30,000	PC-LR=0.35	0.999	80,000	85.7
30,000	CLR (0.1-3)	0.95	10,000	89.6
20,000	PC-LR=0.35	0.999	80,000	82.7
20,000	CLR (0.1-3)	0.95	10,000	87.9
10,000	PC-LR=0.35	0.999	80,000	71.4
10,000	CLR (0.1-3)	0.95	10,000	80.6

Table 1: Comparison of final accuracy results for various training regimes of Resnet-56 on Cifar-10. BN MAF is the value use for the *moving_average_fraction* parameter with batch normalization. PC-LR is a standard piecewise constant learning rate policy described in Section 2 with an initial learning rate of 0.35.


На других моделях и сетях тоже работает

Super-Convergence не ограничивается экспериментами на ResNet-56.

В статье рассматриваются CIFAR-10/100, MNIST и ImageNet, а также архитектуры ResNet, Wide ResNet, DenseNet и Inception. Ниже приведен график для inception



(a) Resnet-50



(b) Inception-resnet-v2

Figure 6: Training resnet and inception architectures on the imagenet dataset with the standard learning rate policy (blue curve) versus a 1cycle policy that displays super-convergence. Illustrates that deep neural networks can be trained much faster (20 versus 100 epochs) than by using the standard training methods.

Основные выводы

1. lr влияет не только на скорость оптимизации. Большие значения меняют динамику SGD, устойчивость около минимумов и неявные предпочтения оптимизатора.
2. Высокий lr может улучшать generalization. Авторы связывают это с эффектом implicit regularization и демонстрируют особенно заметное преимущество на небольших обучающих выборках.
3. 1cycle позволяет эффективно использовать большие lr . Увеличение в первой части обучения и последующее уменьшение дают возможность сочетать агрессивную оптимизацию с финальной сходимостью.
4. Регуляризацию необходимо настраивать совместно с lr . Высокие lr могут требовать уменьшения weight decay и других регуляризаторов.
5. Super-Convergence может существенно сократить вычислительные затраты. В экспериментах статьи встречается ускорение по числу итераций вплоть до 10x